

## Hito 1: Definición del problema y determinación del alcance

Desarrollo e Integración de Servicios de IA  
Máster Universitario en Ingeniería Informática  
2024 - 2025

### Integrantes:

Alejandro Navarro de la Cruz

Javier Domingo Collado

Juan Miguel García González

Alonso Illán Martínez del Santo

## Contenido

1. Introducción .....	3
2. Características del equipo y roles .....	3
3. Definición del problema .....	4
4. Determinación del alcance del proyecto .....	5
4.1. Dominio del problema .....	5
4.2. Dominio de la solución .....	5
4.3. Evaluación del Proyecto .....	6
4.4. Planificación del Proyecto .....	7
4.4.1. Metodología de desarrollo .....	7
4.4.2. Ciclo de Vida de Machine Learning.....	7
4.5. Presupuesto del Proyecto .....	8
Bibliografía .....	10

## Índice de figuras

Figura 1. Exactitud .....	6
Figura 2. Precisión.....	6
Figura 3. Recall .....	6
Figura 4. F1-score .....	6
Figura 5. Retorno de la Inversión .....	7

## Índice de tablas

Tabla 1. Características del equipo y roles .....	4
---	---

# 1. Introducción

El presente documento se enmarca en la etapa inicial del ciclo de vida de un proyecto de Machine Learning, Definición del problema y determinación del alcance. El documento se divide en tres grandes secciones: 2. Características del equipo y roles, 3. Definición del problema y 4. Determinación del alcance del proyecto.

En la primera sección, se expondrá una tabla con los diferentes integrantes del equipo, junto con un rol asignado y sus responsabilidades. En la segunda sección del documento, se llevará a cabo una definición detallada del problema que nuestro proyecto de Machine Learning busca resolver. Finalmente, en la última sección del documento, se abordarán aspectos como el dominio del problema, el dominio de la solución, la evaluación del proyecto, la planificación y el presupuesto, definiendo los desafíos a resolver, el enfoque técnico, la viabilidad, los hitos clave y los recursos necesarios para su implementación.

El objetivo de este documento es establecer una definición precisa del problema y una determinación detallada del alcance para nuestro proyecto de Machine Learning.

## 2. Características del equipo y roles

En esta sección se establecerán los miembros del equipo, compuesto por cuatro personas, y sus respectivos roles dentro del desarrollo del proyecto de Machine Learning. Cada uno de los integrantes asumirá una función específica, alineada con las fases del ciclo de vida de un proyecto de ML, garantizando que todas las áreas clave están adecuadamente gestionadas.

Además, se han escogido los siguientes roles del temario de la asignatura para el equipo del proyecto: un **Científico de datos**, encargado de construir y ajustar modelos que respondan a las necesidades del proyecto y asegurarse de que sean operativos en el entorno de producción; un **Ingeniero de datos**, que se ocupa de optimizar la recuperación y el uso de datos para garantizar que los modelos cuenten con datos de calidad; un **Ingeniero Informático**, responsable de integrar los modelos en las aplicaciones y sistemas de la empresa, asegurando su correcto funcionamiento; y por último un **Experto en la materia**, que proporciona el contexto necesario, define las preguntas de negocio y establece los KPIs que guiarán el desarrollo del modelo y su evaluación continua.

También, el equipo se caracteriza por ser multidisciplinar, dónde cada integrante aporta sus conocimientos clave en su área para garantizar el éxito del proyecto. Además, se promoverá un enfoque colaborativo, fomentando la comunicación y el trabajo en equipo para resolver los problemas y optimizar las soluciones. Finalmente, el equipo estará orientado a resultados, asegurando la implementación de un modelo funcional y eficiente que cumpla con los hitos establecidos en la 4.4. Planificación del Proyecto.

A continuación, en la Tabla 1, se ha elaborado una tabla resumen con la información de los integrantes del equipo junto con la asignación de los roles seleccionados.

Tabla 1. Características del equipo y roles

Integrantes del equipo	Rol establecido
Juan Miguel García González	Científico de datos
Javier Domingo Collado	Ingeniero de datos
Alejandro Navarro de la Cruz	Ingeniero Informático
Alonso Illán Martínez del Santo	Experto en la materia

### 3. Definición del problema

En situaciones de desastre natural [1], como puede ser un tsunami, la capacidad de evaluar rápida y precisamente la condición de las vías de transporte resulta fundamental para poder coordinar aquellas operaciones derivadas del desastre, como son el rescate y la logística humanitaria. En este caso, las carreteras pueden quedar gravemente afectadas, ya sea por escombros, inundaciones o cualesquiera obstáculos que afectan gravemente a la capacidad de la respuesta de los servicios de emergencia.

La identificación temprana de las obstrucciones en las vías nos permite:

- **Coordinar operaciones de rescate y socorro:** Identificando rutas accesibles que permiten acudir al auxilio de las emergencias derivadas del fenómeno natural.
- **Optimizar rutas logísticas para la entrega de suministros esenciales:** En situaciones críticas resulta crucial la entrega de suministros alimentarios, agua y demás víveres.
- **Evaluar el daño de infraestructuras críticas:** Puentes colapsados, carreteras inundadas...
- **Apoyo en la toma de decisiones por parte de las autoridades:** Mejor coordinación para la distribución de recursos y personal.

Para esta casuística, las imágenes aéreas captadas por drones o satélites resultan una fuente valiosa de datos en tiempo real, pero el análisis manual de dichas imágenes resulta en un proceso lento y costoso, además de estar sujeto a error humano, especialmente en estas situaciones de alta presión como un desastre natural, por lo que se hace necesaria la implementación de un sistema automatizado de detección de objetos para evaluar la transitabilidad de las vías, ofreciendo respuestas efectivas y eficientes ante este desafío.

## 4. Determinación del alcance del proyecto

### 4.1. Dominio del problema

El dominio del problema que abordaremos en este proyecto se centra en la detección y clasificación automática de objetos en imágenes aéreas obtenidas a través de drones o satélites. Esta problemática tiene diversas aplicaciones en distintos sectores, destacándose principalmente en la gestión de emergencias y monitoreo de infraestructuras críticas. El objetivo es desarrollar un sistema basado en inteligencia artificial capaz de procesar grandes volúmenes de imágenes en tiempo real, permitiendo la identificación temprana de obstáculos y daños en carreteras, edificios y otras infraestructuras clave.

En el ámbito de la gestión del tráfico y la seguridad, este sistema facilitará la detección de vehículos en carretera, el análisis de la congestión de vehículos y la evaluación de las condiciones de las vías de transporte. En el sector agrícola, permitirá la identificación de cultivos, la detección de áreas afectadas por plagas o cambios ambientales y la optimización del uso de recursos hídricos. En cuanto al monitoreo de infraestructuras, se podrá evaluar el estado de edificaciones, detectar daños en puentes y carreteras y monitorear cambios estructurales en entornos urbanos. Como punto a añadir, en situaciones de desastres naturales, el sistema podrá identificar escombros, inundaciones y otros obstáculos en carreteras, facilitando la planificación de rutas de emergencia y el despliegue de ayuda humanitaria. Actualmente, la inspección y análisis de estas imágenes se realiza de manera manual, lo que implica un alto consumo de tiempo y recursos, además de estar sujeto a errores humanos.

La implementación de un sistema automatizado basado en modelos de visión por computadora permitirá optimizar estos procesos, ofreciendo una solución rápida y eficiente para la toma de decisiones en tiempo real.

### 4.2. Dominio de la solución

Para abordar el problema identificado, se propone una solución basada en el uso de inteligencia artificial y visión por computadora. Esta solución se estructurará en varias fases clave que permitirán la identificación y clasificación eficiente de objetos en imágenes aéreas. En primer lugar, se llevará a cabo la recolección y preprocesamiento de datos, obteniendo imágenes aéreas de diversas fuentes, aplicando técnicas de mejora de calidad como ajuste de contraste y eliminación de ruido, y realizando un etiquetado detallado de los datos para la correcta identificación de los objetos de interés. Posteriormente, se desarrollará el modelo de detección de objetos, utilizando algoritmos avanzados como YOLO, Faster R-CNN y SSD, entrenados con datasets especializados como DOTA, xView y AID. Una vez entrenado, el modelo será evaluado mediante métricas clave como precisión, recall y F1-score para garantizar su efectividad.

Tras esta fase, se procederá a la implementación y despliegue de la solución mediante el desarrollo de una API o interfaz de usuario que permita la visualización de los resultados en tiempo real, además de su integración con plataformas móviles y web para su uso en campo por organismos de emergencia y monitoreo de infraestructuras. Se optimizará el

modelo para su ejecución eficiente en dispositivos de bajo consumo, como drones y hardware portátil. Finalmente, el sistema será sometido a un monitoreo y mejora continua, evaluando su desempeño en entornos reales y recopilando nuevos datos para mejorar su precisión. Se aplicarán técnicas de aprendizaje transferido para optimizar su capacidad de detección en distintos escenarios, además de ajustes periódicos en los hiperparámetros y mejoras en la infraestructura del sistema para garantizar su escalabilidad. Con esta solución, se busca ofrecer un sistema robusto y eficiente que facilite la toma de decisiones en situaciones críticas, mejorando la capacidad de respuesta ante emergencias y optimizando la gestión de infraestructuras estratégicas.

### 4.3. Evaluación del Proyecto

Se utilizarán los indicadores clave de desempeño (KPIs) dado que permiten establecer medidas objetivas y cuantificables para evaluar el rendimiento del proyecto, en este caso se utilizarán los siguientes:

- **Precisión y Sensibilidad:** Medición de la tasa de detección correcta y clasificación de objetos en las imágenes, evaluada a través de métricas como [2]:
  - **Exactitud** (Verdaderos positivos+ Verdaderos Negativos)/Total

$$\text{Accuracy} = \frac{\text{correct classifications}}{\text{total classifications}} = \frac{TP + TN}{TP + TN + FP + FN}$$

Figura 1. Exactitud

- **Precisión** (Verdaderos positivos)/( Verdaderos positivos + Falsos positivos)

$$\text{Precision} = \frac{\text{correctly classified actual positives}}{\text{everything classified as positive}} = \frac{TP}{TP + FP}$$

Figura 2. Precisión

- **Recall** (Verdaderos positivos)/( Verdaderos positivos + Falsos negativos)

$$\text{Recall (or TPR)} = \frac{\text{correctly classified actual positives}}{\text{all actual positives}} = \frac{TP}{TP + FN}$$

Figura 3. Recall

- **F1-score**  $2*((\text{Precisión} * \text{Recall}) / (\text{Precisión} + \text{Recall}))$

$$F1 = 2 * \frac{\text{precision} * \text{recall}}{\text{precision} + \text{recall}} = \frac{2TP}{2TP + FP + FN}$$

Figura 4. F1-score

- **Retorno de la Inversión (ROI):** Estimación del impacto económico del sistema, considerando la reducción de tiempos de respuesta y los costes asociados a intervenciones manuales en situaciones de desastre  $((\text{Ingresos Totales} - \text{Costes Totales}) / \text{Costes Totales} \times 100)$

$$ROI = \frac{(\text{Ingresos Totales} - \text{Costes Totales})}{\text{Costes Totales}} \times 100$$

Figura 5. Retorno de la Inversión

- **Disponibilidad y Rendimiento del Sistema:** Medición del uptime (tiempo que un servicio) y la capacidad de respuesta del entorno de producción, asegurando que la solución mantiene un rendimiento óptimo incluso en condiciones de alta demanda.

## 4.4. Planificación del Proyecto

### 4.4.1. Metodología de desarrollo

Para este proyecto, seguiremos una metodología Agile Hybrid [3], que consiste en un enfoque que combina la planificación estructurada de la metodología Waterfall, con la iteración flexible de Agile, de manera que podemos adaptarnos perfectamente al Ciclo de Vida de Machine Learning.

La decisión de usar esta metodología viene dada por dos razones principales:

- **Secuencialidad en las fases:** Las fases requieren una planificación detallada, un alcance definido y entregables claros, por lo que se requiere un enfoque lineal aportado por la metodología Waterfall.
- **Necesidad de iteración:** En las fases de Datos y Modelados es necesario probar, ajustar y mejorar de manera continua, alineándose con los objetivos de Agile, necesitando iteraciones cortas y retroalimentación constante.

Gracias a la elección de esta metodología, se nos permitirá contar con la adaptabilidad y flexibilidad necesarias para el modelado y los datos, así como poder seguir el Ciclo de Vida de Machine Learning, obteniendo una constante colaboración y retroalimentación para poder afinar el sistema.

### 4.4.2. Ciclo de Vida de Machine Learning

Para este proyecto, seguiremos el Ciclo de Vida de Machine Learning, compuesto por una serie de fases interdependientes y cíclicas, permitiendo sistematizar el desarrollo de los modelos y su integración.

#### Definición

En esta fase del proyecto se establecen los cimientos sobre los que se desarrollará el ML, usando un enfoque Waterfall debido a la necesidad de planificación detallada y un alcance claramente definido. Encontramos dos fases:

- **Definición del proyecto:** Se establece el propósito del proyecto, métricas clave e impacto esperado, definiendo el problema con las entradas y salidas esperadas.
- **Determinación del alcance:** Se identifica el dominio del problema, el dominio de la solución y la viabilidad técnica. Se define hasta donde llegará el modelo y las métricas que se utilizarán para evaluarlo.

### *Datos*

La fase de datos se gestiona mediante iteraciones ágiles, debido a la naturaleza cíclica de la recopilación, limpieza y etiquetado de datos de un proyecto ML, requiriendo flexibilidad y adaptabilidad. Encontramos dos fases:

- **Definición y Línea Base:** Se definen las fuentes de datos y se establece una línea base para las imágenes. Se determina el formato, resolución, duración otros atributos de los datos.
- **Etiquetado y Organización:** Garantizaremos un etiquetado consistente y organizaremos los datos de manera efectiva. Se realizará un etiquetado semántico y una segmentación de las instancias.

### *Modelo*

El entrenamiento y ajuste del modelo requieren iteraciones cíclicas e incrementales para optimizar la precisión y generalización del modelo. Se gestionará con Agile para el desarrollo y análisis. Encontramos dos fases:

- **Selección y Entrenamiento del Modelo:** Utilizando datos organizados y etiquetados, para entrenar el modelo e incluso usar modelos previamente entrenados para optimizar el entrenamiento.
- **Análisis de Errores:** Identificación de errores de clasificación y segmentación, evaluando el modelo con las métricas establecidas y realizando una retroalimentación iterativa para ajustar el modelo.

### *Despliegue*

La fase de despliegue se gestiona mediante un enfoque Waterfall debido a la necesidad de una planificación detallada y secuencial. Encontramos dos fases:

- **Producción:** Integrar el modelo en un entorno de producción robusto y escalable.
- **Monitorización:** Evaluar el rendimiento del modelo en condiciones del mundo real y gestionar la deriva de los datos.

## 4.5. Presupuesto del Proyecto

Se presenta a continuación una estimación preliminar de los recursos económicos necesarios.

En cuanto a computación se necesitará acceso a GPUs: Se prevé el uso de plataformas como Google Colab Pro, AWS EC2 o Azure para el entrenamiento de modelos. Dependiendo del volumen y la frecuencia de los entrenamientos, se estima un coste aproximado de 200 a 400 euros [4].

Para los datos obtendremos los datos de datasets públicos, pudiendo aprovechar datos abiertos, se minimizan los costes asociados a la recopilación y validación de información, sin embargo, será necesario realizar una anotación manual en caso de que los datos no estén etiquetados.

Para el desarrollo se utilizará Python y librerías de código abierto, por lo que no suponen un coste directo. No obstante, se debe considerar la inversión en tiempo de desarrollo,



integración y personalización, lo que se traduce en costes asociados a recursos humanos y horas de trabajo.

En cuanto a la infraestructura, se prevé un despliegue local inicial para comprobar el funcionamiento por lo que no será necesario realizar inversiones en este punto.

El cálculo de la mano de obra en este caso al ser un proyecto educativo no supondrá coste más allá del tiempo de los integrantes del grupo.

## Bibliografía

- [1] A. I. Martínez del Santo, «EvalFlood4ITS: Diseño de un Sistema de Transporte Inteligente para responder ante Maremotos,» de *Actas de las XIX Jornadas de Ciencia e Ingeniería de Servicios (JCIS 2024)*, A Coruña, 2024.
- [2] GOOGLE, «Clasificación: Exactitud, recuperación, precisión y métricas relacionadas,» 2024. [En línea]. Available: <https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=es-419>. [Último acceso: 2025].
- [3] D. Nieves Narducci, «Agile Hybrid: Enfoque flexible para proyectos complejos,» 18 diciembre 2024. [En línea]. Available: <https://openwebinars.net/blog/agile-hybrid-enfoque-flexible-para-proyectos-complejos/>. [Último acceso: 23 febrero 2025].
- [4] aws, «Train and tune a deep learning model at scale,» [En línea]. Available: <https://aws.amazon.com/es/tutorials/train-tune-deep-learning-model-amazon-sagemaker/>. [Último acceso: 2025].